

Comparación entre Fine-Tuning y Prompting para la clasificación de temas

Gorka Fernández Sandín
University of the Basque Country (UPV/EHU)
gorkafernandez085@ikasle.ehu.eus

Abstract

La clasificación automática de textos es una tarea fundamental en el Procesamiento del Lenguaje Natural, tradicionalmente abordada mediante modelos entrenados de forma supervisada. Sin embargo, la aparición de grandes modelos de lenguaje ha popularizado el uso de técnicas basadas en prompting, donde un modelo generativo realiza la tarea sin entrenamiento adicional. En este trabajo se comparan ambos enfoques en la tarea de clasificación temática de noticias. Por un lado, se entrena un modelo encoder ligero (DistilBERT) mediante fine-tuning supervisado. Por otro, se evalúa el uso de modelos generativos instruccionales (Qwen-1.5B y LLaMA-3.1-8B) mediante prompting. Además, se realiza un análisis de errores y se estudia el impacto del data augmentation mediante paráfrasis automáticas. Los resultados muestran que el fine-tuning sigue siendo claramente superior en tareas de clasificación mientras que el prompting presenta limitaciones estructurales, incluso al aumentar el tamaño del modelo.

1 Introducción

La clasificación automática de documentos es una de las tareas clásicas del PLN, con aplicaciones directas en sistemas de recomendación, organización de contenidos, análisis de opinión y recuperación de información. Esta tarea se solía abordar mediante modelos entrenados de forma supervisada que aprenden a asignar una etiqueta temática a cada texto a partir de ejemplos anotados.

En los últimos años, la aparición de grandes modelos ha introducido un nuevo paradigma basado en el uso de prompting. En este enfoque, un modelo generativo previamente entrenado es capaz de realizar una tarea específica simplemente siguiendo instrucciones en lenguaje natural sin necesidad de ajustar sus parámetros. Este método resulta especialmente atractivo por su flexibilidad y por reducir el coste de entrenamiento. Esto ha llevado a

plantear si podría sustituir a los enfoques clásicos basados en fine-tuning.

El objetivo de este trabajo es analizar de forma empírica hasta qué punto el prompting puede competir con el fine-tuning en una tarea de clasificación multiclase. Para ello, se estudia la clasificación de noticias en cinco categorías temáticas utilizando dos enfoques claramente diferenciados. Por un lado, se entrena un modelo encoder ligero mediante aprendizaje supervisado. Por otro, se emplean modelos generativos instruccionales que realizan la clasificación únicamente a partir de prompts cuidadosamente diseñados.

Además, se realiza un análisis detallado de los errores cometidos por los modelos generativos lo que permite identificar patrones de fallo recurrentes. A partir de este análisis, propongo una estrategia de data augmentation basada en paráfrasis automáticas con el objetivo de mejorar la robustez del modelo entrenado. Así, el trabajo no solo compara ambos paradigmas, sino que también explora técnicas prácticas para mejorar el rendimiento en escenarios reales.

2 Trabajos relacionados

La clasificación de textos ha sido muy estudiada en el ámbito del Procesamiento del Lenguaje Natural. Con la introducción de modelos basados en transformers, como BERT, el fine-tuning de modelos preentrenados se ha consolidado como el enfoque dominante para tareas de clasificación. Logrando así mejoras significativas respecto a métodos basados en características manuales o modelos secuenciales tradicionales. Versiones más ligeras como DistilBERT han demostrado que es posible mantener un rendimiento competitivo reduciendo considerablemente el coste computacional.

En paralelo, el desarrollo de grandes modelos de lenguaje generativos ha dado lugar a un nuevo paradigma basado en prompting. En este enfoque,

el modelo realiza la tarea a partir de instrucciones en lenguaje natural sin necesidad de entrenamiento adicional. Este método puede ser eficaz en tareas abiertas o de generación de texto, especialmente cuando se emplean modelos de gran tamaño y prompts cuidadosamente diseñados.

Sin embargo, se puede observar como el prompting presenta limitaciones en tareas discriminativas, como la clasificación multiclase. Esto se debe a la ausencia de una señal de error explícita que provoca comportamientos degenerados como el sesgo hacia clases mayoritarias. Además, el rendimiento suele depender fuertemente del tamaño del modelo y de la distribución de los datos.

Por otro lado, el data augmentation se ha utilizado tradicionalmente como una estrategia para mejorar la generalización de modelos supervisados. En tareas de clasificación de texto, técnicas como la paráfrasis automática permiten generar ejemplos adicionales manteniendo la etiqueta original. Esto permite aumentar la robustez del modelo sin necesidad de tener nuevos datos anotados. Este trabajo combina estas líneas de investigación para analizar de forma comparativa los enfoques basados en fine-tuning y prompting en un mismo escenario experimental.

3 Descripción del sistema

En este trabajo comparo dos enfoques claramente diferenciados para la tarea de clasificación temática de noticias: el entrenamiento supervisado de un modelo encoder y el uso de modelos generativos mediante prompting. Además, propongo una estrategia de data augmentation para mejorar la robustez del modelo entrenado.

3.1 Modelo encoder con fine-tuning

Como enfoque base utilizo DistilBERT, una versión comprimida de BERT que mantiene gran parte de su capacidad representacional con un menor coste computacional. DistilBERT es un modelo encoder basado en la arquitectura transformer. Está diseñado para generar representaciones contextualizadas de texto que pueden ser empleadas eficazmente en tareas de clasificación.

El modelo se adapta a la tarea mediante fine-tuning supervisado, añadiendo una capa de clasificación sobre la representación del token [CLS]. El entrenamiento es realizado utilizando datos anotados, optimizando una función de pérdida de entropía cruzada para una clasificación multiclase

con cinco categorías. Este enfoque representa el paradigma clásico y ampliamente validado en tareas de clasificación de texto.

3.2 Modelos generativos con prompting

Como alternativa al fine-tuning, he evaluado el uso de modelos generativos instruccionales para realizar la clasificación sin entrenamiento adicional. En concreto, he usado los modelos Qwen-1.5B-Instruct y LLaMA-3.1-8B-Instruct, ambos preentrenados para seguir instrucciones en lenguaje natural.

En este enfoque, la clasificación se formula como un problema de generación de texto. Para cada noticia, se construye un prompt que describe explícitamente la tarea y las categorías posibles, solicitando al modelo que devuelva únicamente la etiqueta correspondiente. El modelo genera la respuesta de forma autoregresiva y la categoría predicha se extrae directamente del texto generado.

Este método nos permite evaluar hasta qué punto los modelos generativos son capaces de realizar tareas discriminativas sin una fase de entrenamiento supervisado específica. No obstante, al no existir retroalimentación explícita sobre los errores, el comportamiento del modelo depende en gran medida de su capacidad previa y del diseño del prompt.

3.3 Estrategia de data augmentation

A partir del análisis de errores de los modelos generativos, se observa un sesgo marcado hacia la clase mayoritaria, lo que pone de manifiesto las limitaciones del prompting en este escenario. Para explorar una posible mejora en el enfoque supervisado, propongo una estrategia de data augmentation basada en la generación de paráfrasis automáticas.

Concretamente, se selecciona un subconjunto del conjunto de entrenamiento y se generan versiones alternativas de cada noticia mediante un modelo generativo. Estas paráfrasis mantienen el significado original del texto y conservan la misma etiqueta. Con esto consigo incrementar el número de ejemplos disponibles para el entrenamiento. Después, el modelo DistilBERT se reentrena utilizando el conjunto de datos ampliado permitiendo analizar el impacto de esta técnica en la robustez y el rendimiento del clasificador.




Figure 1: Distribución real de las clases en el conjunto de datos BBC News.

4 Datos

Los experimentos se realizan utilizando el conjunto de datos BBC News, un corpus ampliamente empleado para la evaluación de sistemas de clasificación de noticias. El dataset contiene artículos periodísticos en inglés categorizados en cinco clases temáticas: *business*, *entertainment*, *politics*, *sport* y *tech*.

El conjunto de datos se divide en particiones de entrenamiento y test, manteniendo la distribución original de las clases. Cabe destacar que el corpus presenta un cierto desbalance, siendo la categoría *business* la más frecuente. Este aspecto resulta relevante para el análisis posterior, ya que influye especialmente en el comportamiento de los modelos generativos evaluados mediante prompting.

Todos los textos se preprocesan mediante tokenización subword utilizando el tokenizador correspondiente a cada modelo. En el caso de DistilBERT, los textos se truncan o rellenan hasta una longitud máxima fija para permitir el entrenamiento en lotes. No se aplican técnicas adicionales de normalización ni filtrado de contenido.

5 Resultados

En esta sección se presentan los resultados obtenidos por los distintos modelos evaluados en la tarea de clasificación temática de noticias. Para medir el rendimiento se ha utilizado las métricas de *accuracy* y *F1-score ponderado* que permiten evaluar tanto el número total de aciertos como el equilibrio en la predicción de clases.

El modelo DistilBERT entrenado mediante fine-tuning supervisado se evalúa sobre el conjunto de test completo. En el caso de los modelos generativos utilizados con prompting, la evaluación de

Modelo	Enfoque	Accuracy	F1
DistilBERT	Fine-tuning	0.972	0.972
Qwen-1.5B	Prompting	0.182	0.056
LLaMA-3.1-8B	Prompting (75)	0.267	0.112
DistilBERT + Aug.	Fine-tuning	0.970	0.970

Table 1: Resultados de clasificación en el corpus BBC News. El modelo LLaMA-3.1-8B se evalúa sobre un subconjunto del conjunto de test debido a limitaciones de memoria.

Qwen-1.5B se realiza sobre todo el conjunto de test, mientras que LLaMA-3.1-8B se evalúa sobre un subconjunto representativo debido a limitaciones de memoria en la GPU. Finalmente, se evalúa nuevamente DistilBERT tras aplicar data augmentation mediante paráfrasis automáticas.

La Tabla 1 resume los resultados obtenidos.

6 Analisis

El análisis de los resultados permite observar diferencias claras entre los enfoques basados en fine-tuning supervisado y aquellos basados en prompting con modelos generativos. En primer lugar, el modelo DistilBERT entrenado mediante fine-tuning alcanza un rendimiento muy elevado con valores cercanos al 97% tanto en accuracy como en F1-score. Este resultado confirma la eficacia de los modelos encoder especializados cuando se dispone de datos anotados y una señal de entrenamiento explícita.

Por el contrario, los modelos generativos utilizados mediante prompting muestran un rendimiento considerablemente inferior. En el caso de Qwen-1.5B, el accuracy obtenido es cercano al 18% lo que coincide aproximadamente con la proporción de la clase *business* en el conjunto de datos. El análisis cualitativo de las predicciones revela un colapso del modelo hacia la categoría *business* independientemente del contenido semántico del texto. Este comportamiento indica que el modelo no está realizando una clasificación real, sino que explota un sesgo estadístico del corpus.

El uso de un modelo generativo de mayor tamaño, LLaMA-3.1-8B, permite mejorar parcialmente el rendimiento, alcanzando un accuracy del 26.7% en un subconjunto del conjunto de test. Este resultado sugiere que el aumento de capacidad del modelo contribuye a una mejor comprensión de la tarea pero no resuelve el problema de fondo. A pesar de su mayor tamaño, el modelo sigue presentando dificultades para discriminar entre clases




Figure 2: Distribución de clases predichas por el modelo Qwen-1.5B mediante prompting. El modelo colapsa hacia la categoría *business*, independientemente del contenido del texto.

temáticamente cercanas y continúa mostrando un sesgo hacia determinadas categorías.

Estos resultados ponen de manifiesto una limitación estructural del enfoque basado en prompting para tareas de clasificación multiclase. Al no existir un proceso de entrenamiento supervisado ni una retroalimentación explícita sobre los errores, los modelos generativos carecen de un mecanismo para corregir comportamientos degenerados como el sesgo hacia la clase mayoritaria.

Finalmente, la estrategia de data augmentation aplicada al modelo DistilBERT no produce una mejora significativa en términos de accuracy, pero mantiene el rendimiento del modelo sin degradación. Este resultado es coherente con el hecho de que el modelo base ya alcanza un rendimiento cercano al óptimo. No obstante, el mantenimiento del rendimiento tras la ampliación del conjunto de entrenamiento sugiere una mayor robustez del modelo y refuerza la ventaja del fine-tuning supervisado frente al prompting en este tipo de tareas.

7 Conclusiones

En este trabajo se ha realizado una comparación empírica entre dos paradigmas ampliamente utilizados en el Procesamiento del Lenguaje Natural para la tarea de clasificación de textos: el fine-tuning supervisado de modelos encoder y el uso de modelos generativos mediante prompting. Los experimentos muestran de forma clara que en un escenario de clasificación multiclase con datos anotados el enfoque basado en fine-tuning sigue siendo muy superior en términos de rendimiento.

El modelo DistilBERT entrenado de forma su-

pervisada alcanza resultados cercanos al 97% de accuracy y F1-score, mientras que los modelos generativos utilizados con prompting presentan un rendimiento considerablemente inferior. En particular, se observa un colapso hacia la clase mayoritaria en el modelo Qwen-1.5B, y una mejora parcial pero insuficiente al aumentar el tamaño del modelo utilizando LLaMA-3.1-8B. Estos resultados ponen de manifiesto las limitaciones estructurales del prompting en tareas discriminativas, donde la ausencia de una señal de error explícita dificulta la corrección de sesgos y errores sistemáticos.

Asimismo, el análisis de data augmentation mediante paráfrasis automáticas muestra que esta técnica permite mantener el rendimiento del modelo entrenado sin degradación. Aumenta su robustez aunque sin producir mejoras significativas en un escenario donde el rendimiento inicial ya es elevado. Este resultado refuerza la idea de que las técnicas de aumento de datos son especialmente útiles para mejorar la estabilidad y generalización de modelos supervisados.

En conjunto, los resultados sugieren que, a pesar de la flexibilidad y facilidad de uso de los grandes modelos generativos, el fine-tuning supervisado sigue siendo la opción más fiable y eficaz para tareas de clasificación de texto cuando se dispone de datos anotados. Como trabajo futuro, se podría explorar el uso de técnicas híbridas que combinen prompting con entrenamiento supervisado ligero, así como la evaluación en dominios con menor disponibilidad de datos.

A Apéndice: Prompts utilizados

A continuación se muestra un ejemplo del prompt utilizado para la clasificación mediante modelos generativos:

You are a text classification system. Classify the following news article into exactly one of the following categories: business, entertainment, politics, sport, tech.

Return only the category name.

References

- AI at Meta. 2024. The llama 3 herd of models. *arXiv preprint arXiv:2407.21783*.
- Jinze Bai and 1 others. 2023. Qwen technical report. *arXiv preprint arXiv:2309.16609*.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*.

([Devlin et al., 2019](#)) (?) ([Bai et al., 2023](#)) ([AI at Meta, 2024](#)) (?)